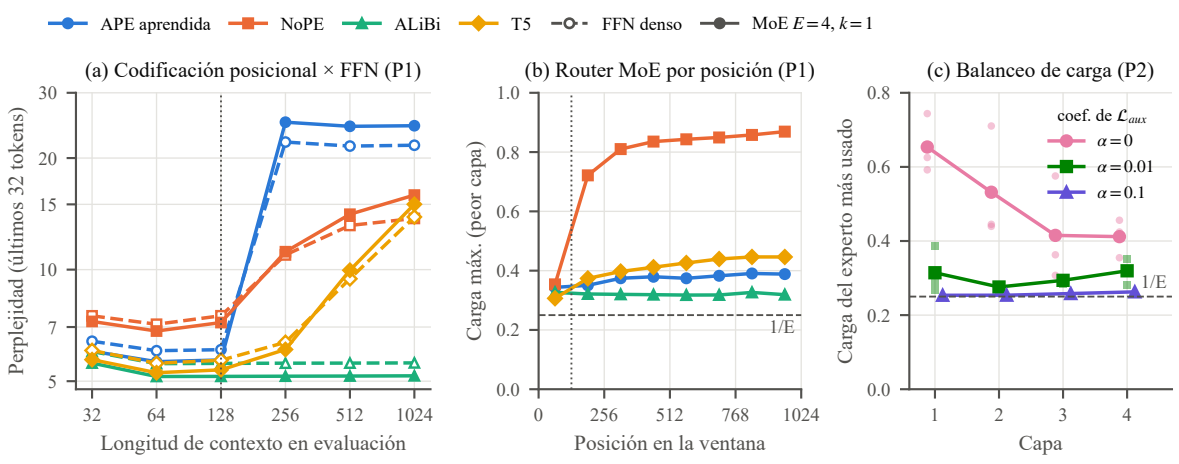
APE aprendida
NoPE
ALiBi
T5
FFN denso
MoE $E=4$, $k=1$
(a) Codificación posicional × FFN (P1)
Perplejidad (últimos 32 tokens)
Longitud de contexto en evaluación
(b) Router MoE por posición (P1)
Carga máx. (peor capa)
1/E
Posición en la ventana
(c) Balanceo de carga (P2)
Carga del experto más usado
coef. de $\mathcal{L}_{aux}$
$\alpha=0$
$\alpha=0.01$
$\alpha=0.1$
1/E
Capa